Evidencia de revisión — migración de input de niveles DGA

Versiones comparadas

	v1.1 (referencia)	v1.2 (esta rama)
Rama	`cr2sub_v1.1`	`cr2sub_v1.2`
Input DGA	844 reportes `dga_xls_*` por pozo	export único `AM006T0034616_1.xlsx`
Carpeta de outputs	`versions/v1.1/`	`versions/v1.2/`

Los CSV de cada carpeta llevan la versión en el nombre (`cr2sub_v1.1_*` y `cr2sub_v1.2_*`), según la variable `version` de los scripts de cada rama. Los resultados de la comparación (v1.1 → v1.2) están en `comparison_v1.1_vs_v1.2/`.

Objetivo: reemplazar `input/DGA_GWL_obs_descarga/dga_xls_*` (844 reportes individuales por pozo, descargados manualmente del portal DGA en 3 tandas) por el archivo único `input/DGA_GWL_obs_descarga/AM006T0034616_1.xlsx` (export tabular largo, 147.180 filas, 1 fila por pozo-fecha-valor).

Scripts modificados: `scripts/01_consolidate.R`, `scripts/functions/functions_consolidate_cr2sub.R` (nueva función `deg2dec_compact` para el formato de coordenadas del nuevo archivo). De paso se corrigió un bug preexistente, no relacionado a la migración, en `scripts/03_process_attributes.R` (`cuencas_BNA.shp` → `Cuencas_BNA.shp`, mismatch de mayúsculas que impedía correr el paso 3).

Método: se guardó una copia de los 3 outputs de la v1.1 (input viejo) en `versions/v1.1/` antes de tocar nada, se corrió el pipeline completo (`01_consolidate.R` → `02_remove_outliers.ipynb` → `03_process_attributes.R`) con el input nuevo, y se comparó celda por celda contra la v1.1 con `scripts/compare_outputs.py` (reproducible, ver sección "Cómo reproducir" abajo). Los resultados de esa comparación quedan en `comparison_v1.1_vs_v1.2/`.

Parte I — Comparación entre versiones (v1.1 vs v1.2)

I.1 Cobertura de pozos

	Pozos v1.1	Pozos v1.2	En común
`gwl_mon.csv` / `gwl_mon_clean.csv` / `attributes.csv`	1137	1133	1133

La brecha son **4 pozos** que existen en las descargas viejas pero no en el export único nuevo (`comparison_v1.1_vs_v1.2/wells_missing_`

Código DGA	Nombre	Cuenca	Subcuenca
02942002-5	PIQUE AV-1	QS. entre Q. La Negra y Q. Pan de Azúcar	Quebrada de Taltal
02942008-4	PIQUE AV - 42	QS. entre Q. La Negra y Q. Pan de Azúcar	Quebrada de Taltal
02942011-4	ESSAN AV - 48	QS. entre Q. La Negra y Q. Pan de Azúcar	Quebrada de Taltal
02942023-8	ESSAN AV - 48	QS. entre Q. La Negra y Q. Pan de Azúcar	Quebrada de Taltal

Los 4 pertenecen a la cuenca de Taltal (prefijos ESSAN y PIQUE AV).

No hay pozos en el archivo nuevo que no existieran antes (0 pozos nuevos "de más").

I.2 Metadatos

De los 1133 pozos en común, **17 valores de metadata** (en 13 pozos) difieren en más de 0.01 entre el input viejo y el nuevo (`comparison_v1.1_vs_v1.2/metadata_diffs.csv`):

cr2sub_id	Nombre	Campo	v1.1	v1.2
1700042	SALAR BELLAVISTA	lat	-21.305833	-20.734444
1700042	SALAR BELLAVISTA	lon	-69.520278	-69.618056
1700042	SALAR BELLAVISTA	elev	946	970
4400037	PARCELA 48 CUATRO ESQUINAS	lat	-29.731944	-29.918889
4400037	PARCELA 48 CUATRO ESQUINAS	lon	-71.230278	-71.269722
4308010	POZO CALVARIO	lon	-70.594722	-70.502778
8114002	POZO COIHUECO en Internado Municipal	lon	-71.871667	-71.838056
1700051/057/076/099-106 (JICA, 9 pozos)	—	elevación	—	-25 a -35 m

Los valores difieren entre las dos fuentes y se usa el que trae cada una. El formato de coordenadas del archivo nuevo (`DDDMMSS` compacto) es uniforme en los 1134 pozos.

Las métricas agregadas `cr2sub_mean_gwl` y `cr2sub_sd_gwl` cambian en 142 y 124 pozos (I.6).

I.3 Series: extensión temporal

Rango de fechas:

Archivo	v1.1	v1.2
`gwl_mon.csv`	1957-04 → 2024-12 (813 meses)	1957-04 → 2026-08 (833 meses)
`gwl_mon_clean.csv`	igual	igual

Ejemplo concreto — pozo `5423019` (el de mayor cobertura reciente), serie mensual completa (`cr2sub_v1.2_gwl_mon.csv`), generada con `scripts/plot_series_extension.py`:

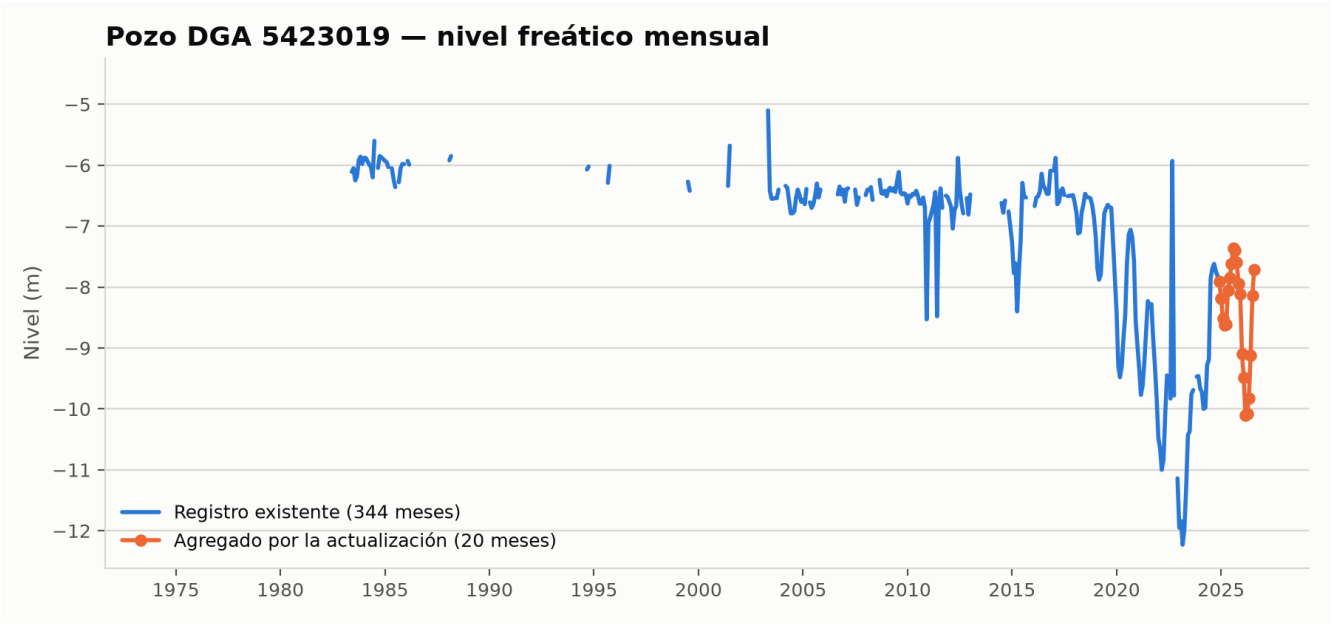


Figure 1: Serie de tiempo pozo 5423019: registro existente en azul, puntos agregados por la actualización en naranja

En azul, el registro que ya existía con el input viejo: 344 meses entre 1974-04 y 2024-12 (los cortes de la línea son huecos reales de medición, no artefactos del gráfico). En naranja, los 20 meses que agrega la actualización, de 2025-01 a 2026-08, enganchados directo a la cola del registro existente — no hay reescritura del histórico, solo extensión hacia adelante. Todos los puntos del tramo en común entre ambas fuentes (hasta 2024-12) son idénticos; el detalle completo de celdas que antes eran `NA` y ahora tienen valor está en `comparison_v1.1_vs_v1.2/gwl_mon_gap_filled.csv` (420 en `gwl_mon.csv`, 840 en `gwl_mon_clean.csv`, repartidas en huecos intermedios de otros pozos además de esta cola).

I.4 Cobertura mensual por región, 2020–2026

Número de pozos con dato en cada mes, por región (norte a sur), para v1.1 y v1.2 con la misma escala de color. La región de cada pozo se asigna por ubicación (cruce espacial con los límites regionales; el polígono más cercano si el punto cae fuera), no por el código DGA, cuyo prefijo es la macrocuenca BNA y no la región. El panel superior (total mensual) superpone ambas versiones: v1.2 en azul grueso y v1.1 en naranja fino. Generado con `scripts/plot_coverage_by_region.py`.

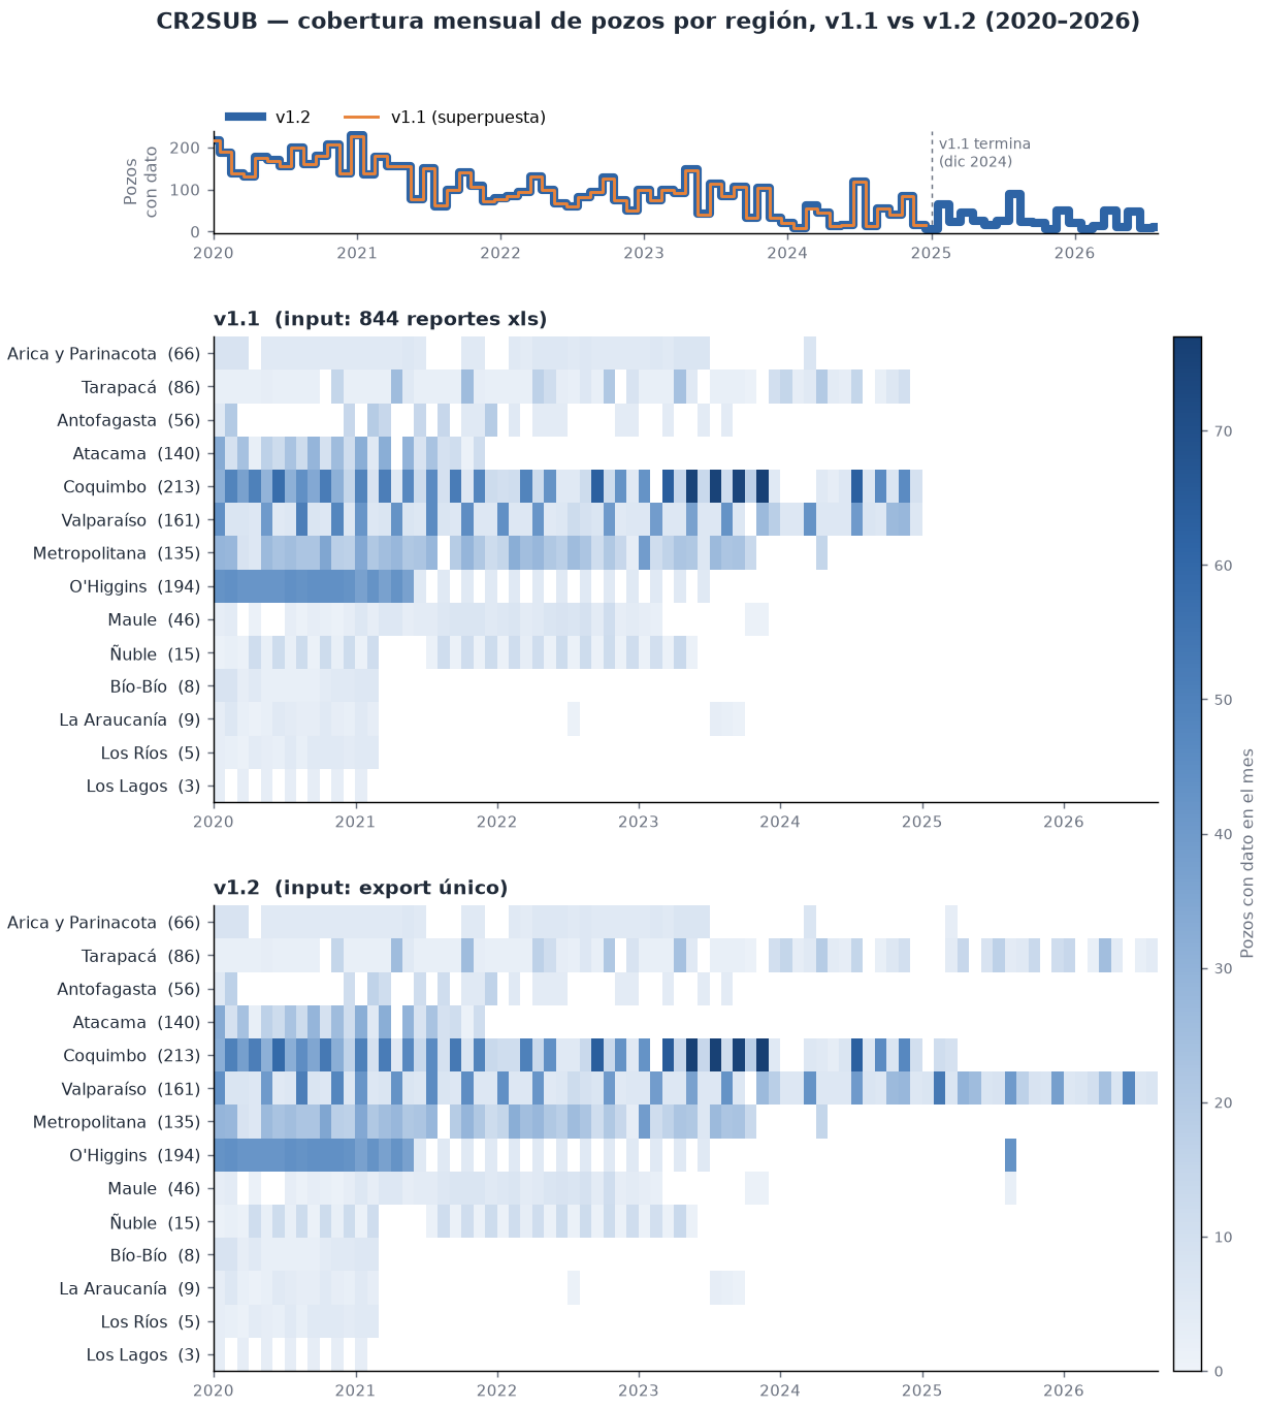


Figure 2: Cobertura mensual de pozos por región, v1.1 vs v1.2, 2020-2026

- Hasta dic-2024 las dos versiones son prácticamente idénticas; la línea naranja corre dentro de la azul.

- Desde 2025 solo v1.2 tiene datos (hasta ago-2026), concentrados en Valparaíso, Tarapacá, Coquimbo y O'Higgins. Las demás regiones no aportan meses nuevos.
- En pozos presentes en ambas versiones, v1.2 suma 600 pozos-mes en 2020–2026 (557 desde 2025 y 43 de huecos rellenados antes) y pierde 1. Por región: Valparaíso 362, Tarapacá 127, Coquimbo 63, O'Higgins 43, Arica y Parinacota 3, Maule 2.
- Los otros 21 pozos-mes que v1.2 no tiene en el periodo corresponden a los 4 pozos privados de Taltal que no están en el export nuevo (I.1).
- La cobertura cae desde ~2020 en ambas versiones y las regiones al sur de O'Higgins casi no tienen datos desde 2021–2023.

I.5 Consistencia de valores de las series

Comparando las **921.129 celdas** (pozo × fecha) presentes en ambas fuentes en `gwl_mon.csv`:

v1.1 → v1.2	Cantidad
Valores idénticos o ambos `NA`	920.708
`NA` antes → con valor ahora (hueco rellenado)	420
Con valor antes → `NA` ahora (dato perdido)	1
Valores contradictorios (mismo pozo/fecha, valor distinto)	**0**

El único dato "perdido" es el pozo `1700028` en 2024-04 (`comparison_v1.1_vs_v1.2/gwl_mon_lost.csv`). En `gwl_mon_clean.csv` (post remoción de outliers) las cifras son 16 perdidos y 840 rellenados.

Resultado: cero conflictos de valor en unos 920 mil puntos comparados; el export único tiene los mismos valores donde coincide con las descargas viejas y más puntos donde había huecos, salvo los 4 pozos de Taltal que no están en él.

I.6 Atributos columna a columna

Generado con `scripts/compare_attributes.py` (`comparison_v1.1_vs_v1.2/attribute_column_diffs.csv`). De las 45 columnas de `attributes.csv`, solo `cr2sub_id` es idéntica; los cambios se agrupan así:

Grupo	Pozos que cambian	Observación
`dga_well_basin` / `subbasin` / `name`	1133 / 712 / 45	El texto cambia de formato (`RIO COPIAPO` → `R. Copiapo`; `EL TRANSITO` → `POZO EL TRANSITO`)
Coordenadas y cota `dga_*` / `cr2sub_*`	14 a 33 según columna	Ver I.2; `cr2sub_elev` y `cr2sub_slp` cambian en 14 pozos
`cr2sub_mean/sd/cv_gwl` (raw y clean)	61 a 142	Ver I.3 e I.5
`cr2sub_*camels*`	306 cambian de cuenca, 77 pasan de NA a tener cuenca, 1 pasa a NA	CAMELS-CL v1 (516 cuencas) → v2 (860 cuencas)
`cr2sub_*bna*`	9	Nuevo criterio: cuenca que contiene al pozo, con buffer de 500 m solo si no cae en ninguna (antes el buffer se aplicaba a todos los pozos)
`cr2sub_clsoilmap_*`	630 a 960	Mediana de la diferencia relativa de 0,06 % a 0,5 %; ver I.8

Pozos sin cuenca CAMELS: 310 en v1.1 → 230 en v1.2. El pozo `5221007` (PAPUDO Y ZAPALLAR, mismas coordenadas) tenía cuenca CAMELS en v1 y no en v2.

I.7 Figuras comparativas de atributos

Figuras generadas con `scripts/compare_plots.py` (`comparison_v1.1_vs_v1.2/fig_*.png`).

A. Estadísticos del nivel. El nivel medio cambia en 142 pozos (mediana 0,05 m, máximo 4,2 m).

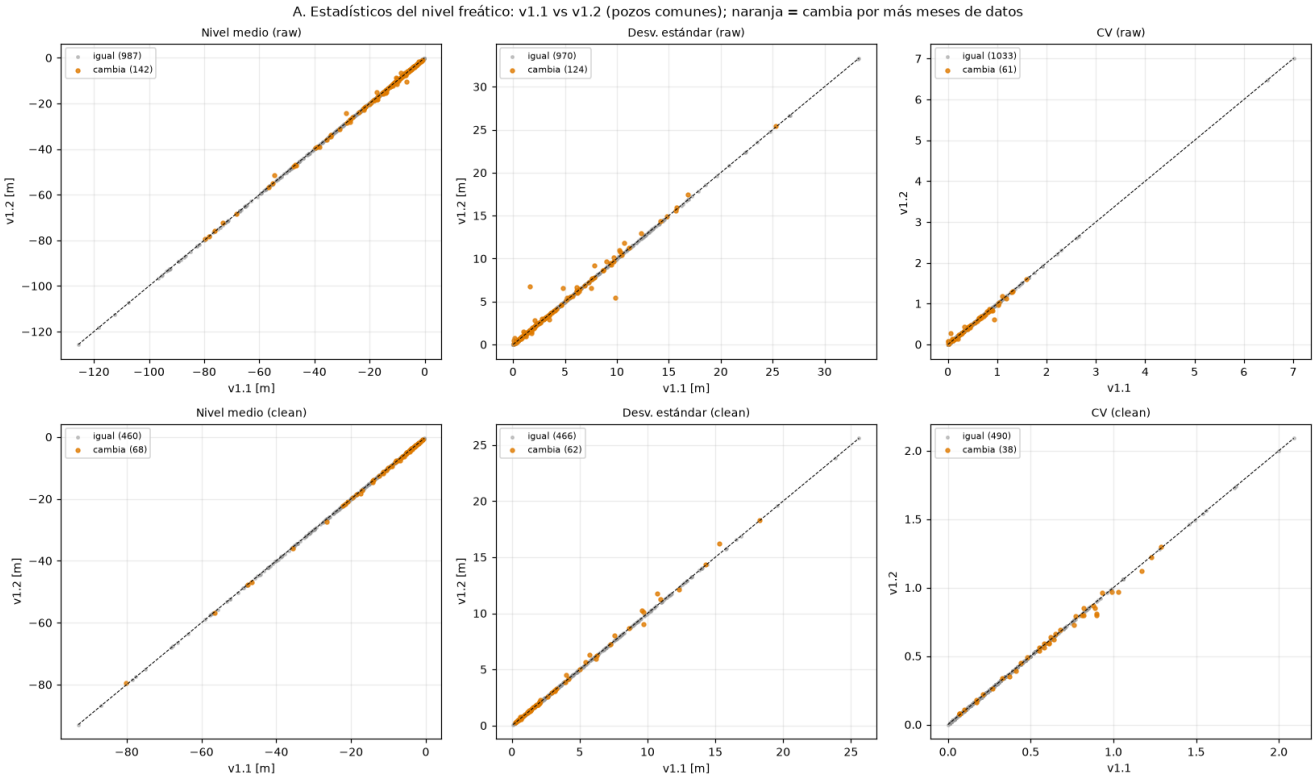


Figure 3: A. Estadísticos del nivel freático, v1.1 vs v1.2

B. Series y filtro de outliers. 162 pozos ganan meses (mediana 2, máximo 167) y 1 pierde. El filtro elimina el 18,5 % de los datos en v1.1 y el 18,2 % en v1.2. 598 de los 1133 pozos tienen menos de 100 meses con dato y quedan sin datos en `gwl_mon_clean.csv` (`min_obs = 100`); en los 535 restantes se elimina el 3,35 %.

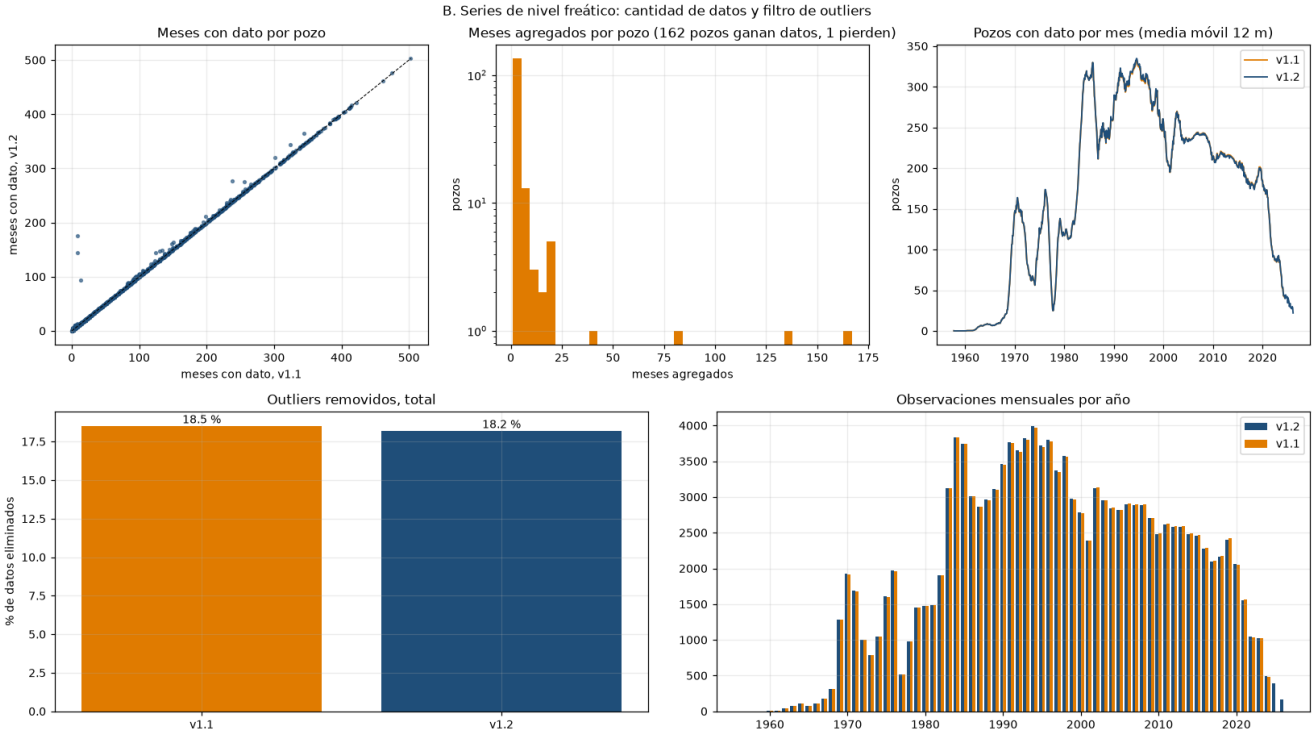


Figure 4: B. Series: cantidad de datos y outliers

C. Ubicación y cota. Diferencia entre la cota reportada por la DGA y la del DEM en la coordenada del pozo, para los 4 pozos que cambian de ubicación (v1.1 → v1.2): `4308010` 1445 m → 9 m, `4400037` 211 m → 2 m, `1700042` 145 m → 4 m, `8114002` 3 m → 1 m. 345 pozos reportan cota 0 en ambas versiones. Hay 227 pozos con diferencia mayor a 200 m en v1.2 (15 si se excluyen los de cota 0); la mediana de |diferencia| es 9,8 m.

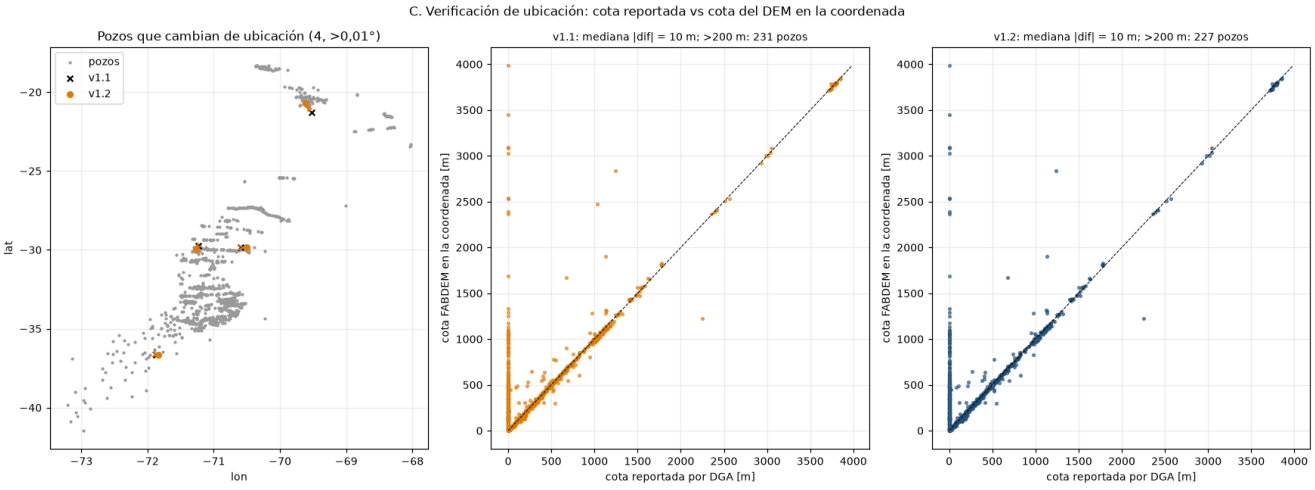


Figure 5: C. Ubicación y cota

D. Cuencas CAMELS. De los 520 pozos que mantienen el mismo `gauge_id`, cambian elevación (mediana 3,1 m, p95 102 m) y precipitación (mediana 0,37 mm, p95 29 mm). En los 306 pozos que cambian de cuenca, la mediana de la diferencia es 223 m de elevación y 50 mm de precipitación.

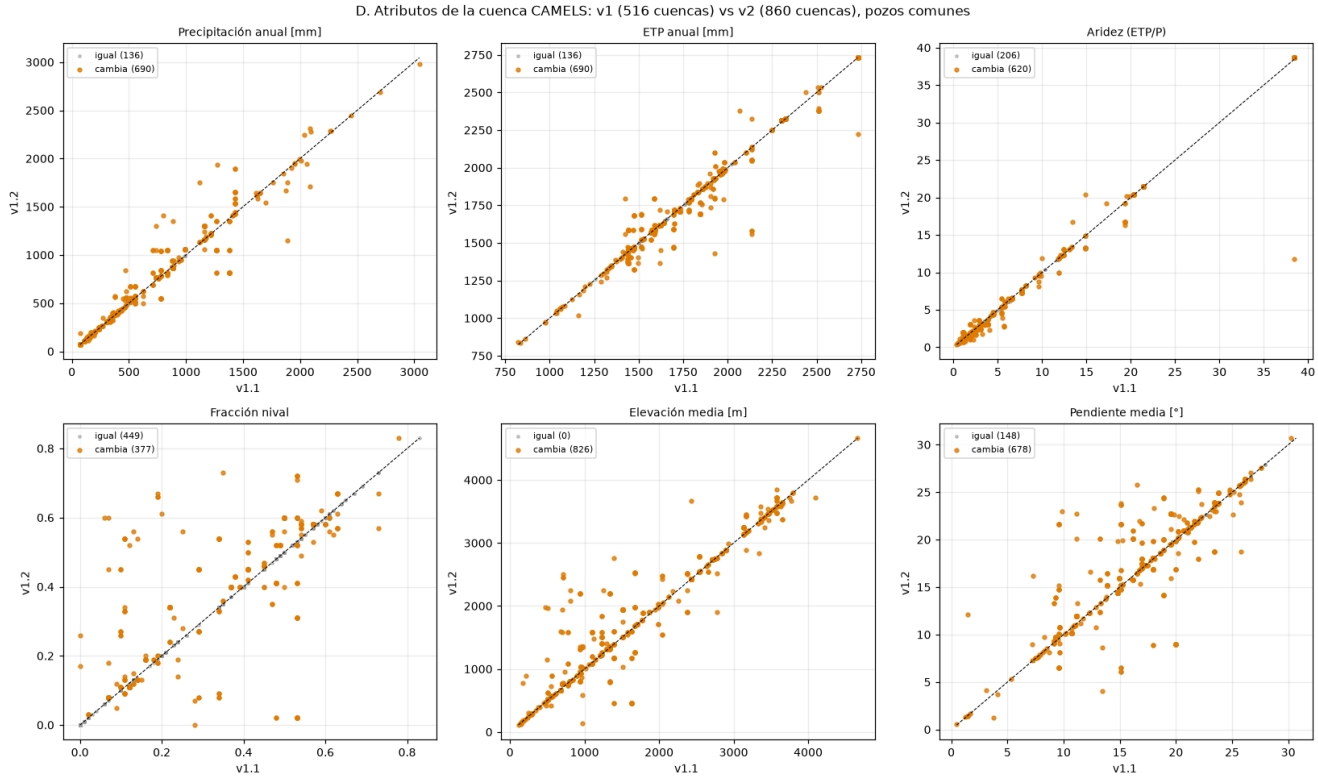


Figure 6: D. Atributos de la cuenca CAMELS

E. Cuencas BNA. 9 pozos BNA cambian de cuenca (paneles superiores).

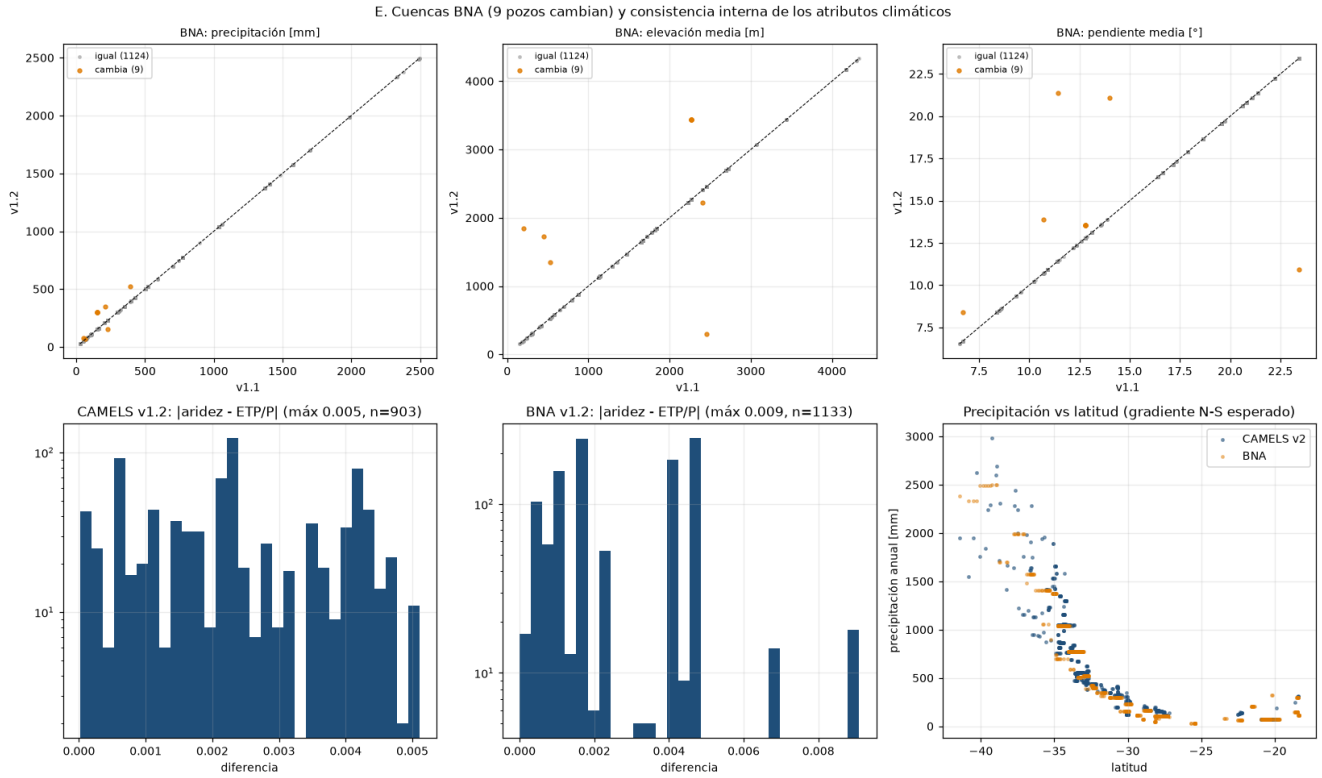


Figure 7: E. BNA y consistencia de los atributos climáticos

I.8 CLSoilMaps entre versiones

Cambio de método. En v1.1 los valores de suelo venían de una extracción original anterior (D. Dinamarca), de la que no tenemos el script. En v1.2 se extraen **todos** los pozos desde los rasters de CLSoilMaps con `scripts/01b_extract_clsoilmaps.R` (promedio en un buffer de 500 m alrededor del pozo); ya no se hereda el CSV anterior. Salidas de esta comparación: `clsoilmaps_v1.1_vs_v1.2_diffs.csv` y `clsoilmaps_v1.1_vs_v1.2.png` en `comparison_v1.1_vs_v1.2/`.

v1.1 vs v1.2 (1064 pozos con dato en ambas versiones): correlación 0,997 a 0,999 en las 10 variables; mediana de la diferencia relativa 0,06 % a 0,5 %; percentil 95 de 0,3 % a 4,6 %. Entre 104 y 596 pozos por variable son idénticos al milésimo. La mediana de la diferencia en AWC 0-100 cm es 0,1 mm (mediana de la variable: 136 mm). La coincidencia es alta, pero no exacta, así que el método original no era el mismo que el actual.

Pozos con coordenadas cambiadas (I.2). Cambian de valor al re-extraer desde la ubicación nueva: `4308010` (AWC 0-100 cm: 146,4 → 135,1 mm), `1700042` (133,8 → 141,6) y `8114002` (215,2 → 230,8). `4400037` tenía valor (94,7 mm) y ahora queda en NA.

Cambios entre valor y NA. `4400017` y `6011022` estaban en NA en v1.1 y ahora tienen dato (124,4 y 136,7 mm) con las mismas coordenadas, y los dos pozos nuevos (`05120007` y `05120011`) tampoco existían en v1.1. Con `4400037` son 5 pozos cuyo estado NA cambia. Pozos con suelo en NA: 68 en v1.1 y 65 en v1.2, de 1133 (fuera de la cobertura de CLSoilMaps).

Pozos con diferencia grande sin cambio de coordenadas. `4320007` pasa de 138,4 a 121,2 mm de AWC 0-100 cm (la mayor diferencia, 17 mm) con las mismas coordenadas. La diferencia máxima en ksat 0-100 cm es 52 cm/día. Como no tenemos el script original, no se puede determinar la causa (por ejemplo, el tratamiento de las celdas parciales del buffer).

Parte II — Comparación con la DGA (solo v1.2)

Se compara `cr2sub_v1.2_*` con el export de la DGA del que sale (`AM006T0034616_1.xlsx`), recalculando en Python, de forma independiente del pipeline en R, las series mensuales y las coordenadas. No interviene v1.1. Script:

scripts/compare_vs_dga.py; salidas en comparison_v1.1_vs_v1.2/vs_dga_*.csv y fig_g_vs_dga.png.

II.1 Pozos y registros

El export tiene 147.180 filas; 358 no tienen código de estación y quedan fuera. De las 146.822 restantes, 7.951 tienen valor menor o igual a 0 y no entran a las series. El export tiene 1.133 pozos y attributes de v1.2 tiene los mismos 1.133.

II.2 Series mensuales

Se recalcula la serie mensual con las reglas del paso 01: promedio de las mediciones repetidas de un mismo pozo y fecha, descarte de valores menores o iguales a 0, promedio mensual y signo invertido. En las 137.975 celdas pozo-mes con dato en ambas fuentes hay 0 diferencias (máximo 2,8e-14 m) y ninguna celda tiene dato solo en una de las dos.

II.3 Coordenadas

- Las coordenadas del export (DDDMMSS), convertidas de forma independiente, coinciden con dga_well_lat y dga_well_lon (diferencia máxima 4,4e-7°).
- cr2sub_lat y cr2sub_lon son iguales a las de la DGA en los 1.133 pozos.
- UTM y lat/lon reportados por la DGA: mediana de la distancia 0,015 km; 1 pozo supera 1 km (4320007, 9,0 km). Para 39 pozos el huso 18 ajusta mejor que el 19 (la DGA no informa el huso).

II.4 Cota

345 pozos tienen cota 0 en el export. En los otros 788 la mediana de |cota DEM − cota DGA| es 6,2 m y 15 pozos superan los 200 m (vs_dga_elev_gt200m.csv).

II.5 Cuenca BNA

El código BNA del polígono que contiene al pozo coincide con los primeros 3 dígitos del código DGA en 1.105 de 1.133 pozos; en 28 difiere (vs_dga_bna_prefix_mismatch.csv; 10 de ellos con prefijo 42 y polígono 43).

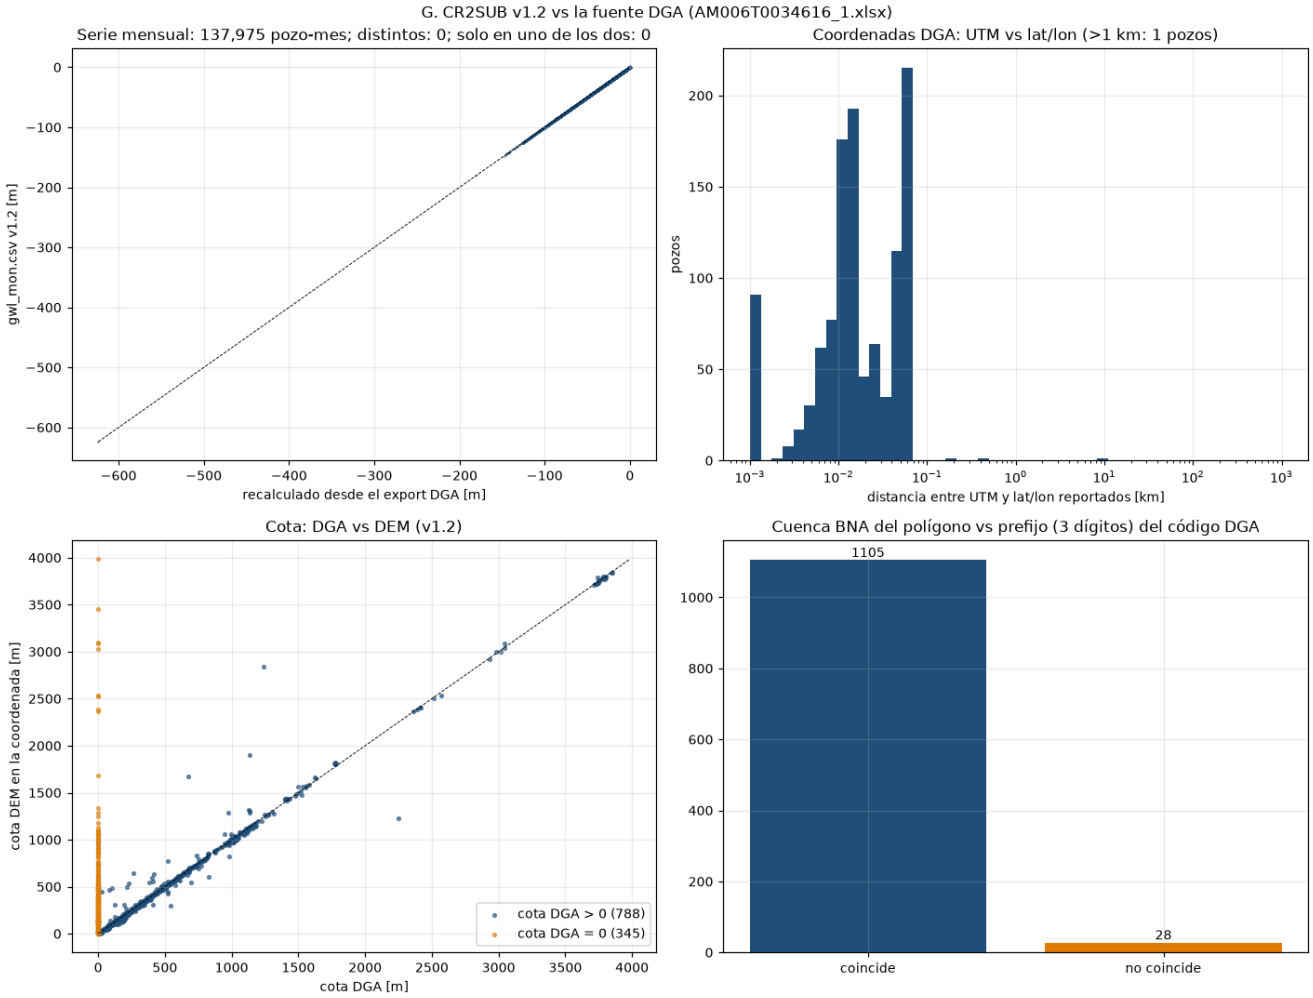


Figure 8: G. CR2SUB v1.2 vs la fuente DGA

Parte III — Otras verificaciones de v1.2

Ni entre versiones ni contra la DGA.

III.1 CLSoilMaps

Script: `compare_attributes.py`. Salidas: `clsoilmaps_*.csv` y `clsoilmaps_v1.1_vs_v1.2.png` en `comparison_v1.1_vs_v1.2/`. La comparación con la v1.1 está en I.8.

Coherencia espacial. Para cada pozo y su vecino más cercano a menos de 5 km (885 pares), la correlación del valor de suelo es 0,78 a 0,95 (por ejemplo arena 0-100 cm: 0,95; arcilla 0-100 cm: 0,92), frente a ~0 para pares al azar. Los dos pozos nuevos tienen AWC 0-100 cm de 130 y 126 mm; sus tres vecinos más cercanos van de 120 a 139 mm.

Verificaciones físicas. Sin valores negativos y densidad aparente entre 0,7 y 2,0 g/cm^3 en todos los pozos. Hay 9 pozos con arcilla + arena $>$ 100 % en 100-200 cm.

F. CLSoilMaps. Mapa de AWC, arcilla y ksat; 65 pozos sin dato (cruces rojas). La comparación numérica está en I.8 y III.1.

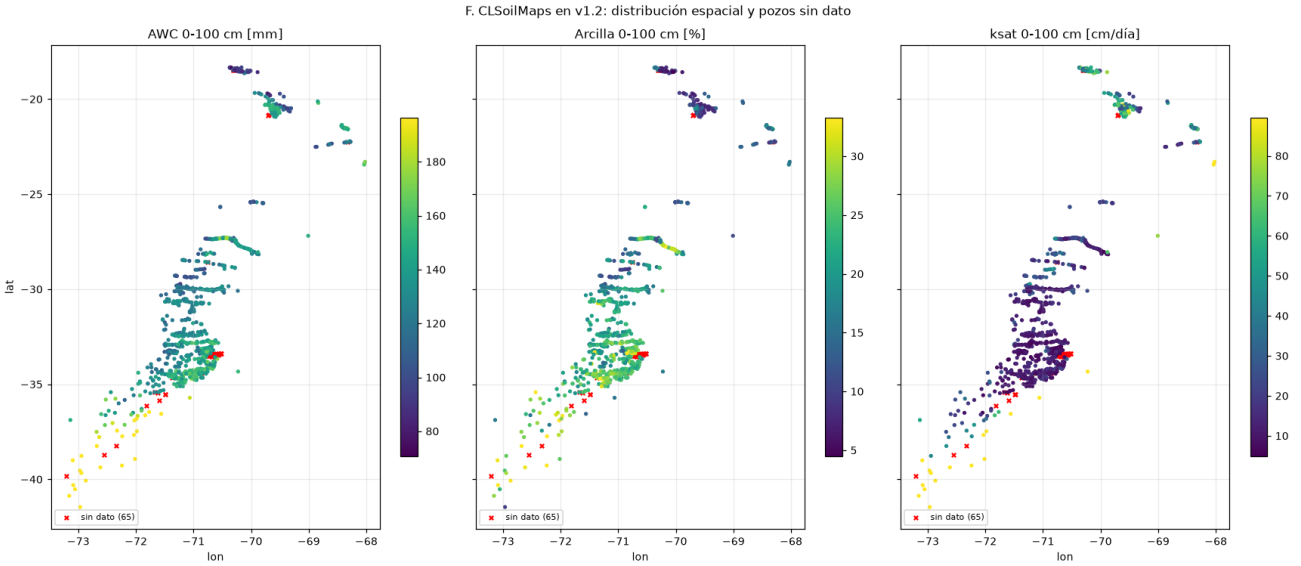


Figure 9: F. CLSoilMaps en v1.2

III.2 Consistencia de los atributos climáticos

La diferencia máxima entre la aridez y ETP/P es 0,005 (CAMELS) y 0,009 (BNA). La fracción nival está dentro de [0, 1] en todos los pozos. La precipitación disminuye de sur a norte (panel inferior de la figura E, en I.7).

III.3 Pipeline

Corrida completa con el input nuevo (`main_pipeline.py`: 01 → 01b → 02 → 03). Las salidas coinciden con las secciones I.1 a I.5; los CSV de `versions/v1.2/` son copia de `cr2sub/`. La asignación a cuencas ahora se regenera con `input/cr2sub_basin_lookup_tables/lookup_table_script.R` (intersección vectorial, sin dependencias externas).

Cómo reproducir

Todo junto (tras `main_pipeline.py`): `review_dga_xlsx_migration/scripts/regenerate_review.sh`. Por partes:

```
cd review_dga_xlsx_migration/scripts
python3 compare_outputs.py        # series y metadatos; solo stdlib
python3 compare_attributes.py     # atributos y CLSoilMaps; pandas, matplotlib
python3 compare_plots.py          # figuras A-F; pandas, matplotlib
python3 compare_vs_dga.py         # Parte II, contra el export DGA; openpyxl, pyproj
python3 plot_series_extension.py; python3 plot_coverage_by_region.py   # figuras; geopandas
```

Lee de `../versions/{v1.1,v1.2}/*.csv` y escribe a `../comparison_v1.1_vs_v1.2/`. Para regenerar `versions/v1.2/` desde cero, correr el pipeline (`scripts/main_pipeline.py`, requiere pandas para el paso 02) y copiar los 3 CSV de `cr2sub/` ahí.