Evidencia de revisión — migración de input de niveles DGA

Versiones comparadas

	v1.1 (referencia)	v1.2 (esta rama)
Rama	`cr2sub_v1.1`	`cr2sub_v1.2`
Input DGA	844 reportes `dga_xls_*` por pozo	export único `AM006T0034616_1.xlsx`
Carpeta de outputs	`versions/v1.1/`	`versions/v1.2/`

Los CSV de cada carpeta llevan la versión en el nombre (`cr2sub_v1.1_*` y `cr2sub_v1.2_*`), según la variable `version` de los scripts de cada rama. Los resultados de la comparación (v1.1 → v1.2) están en `comparison_v1.1_vs_v1.2/`.

Objetivo: reemplazar `input/DGA_GWL_obs_descarga/dga_xls_*` (844 reportes individuales por pozo, descargados manualmente del portal DGA en 3 tandas) por el archivo único `input/DGA_GWL_obs_descarga/AM006T0034616_1.xlsx` (export tabular largo, 147.180 filas, 1 fila por pozo-fecha-valor).

Scripts modificados: `scripts/01_consolidate.R`, `scripts/functions/functions_consolidate_cr2sub.R` (nueva función `deg2dec_compact` para el formato de coordenadas del nuevo archivo). De paso se corrigió un bug preexistente, no relacionado a la migración, en `scripts/03_process_attributes.R` (`cuencas_BNA.shp` → `Cuencas_BNA.shp`, mismatch de mayúsculas que impedía correr el paso 3).

Método: se guardó una copia de los 3 outputs de la v1.1 (input viejo) en `versions/v1.1/` antes de tocar nada, se corrió el pipeline completo (`01_consolidate.R` → `02_remove_outliers.ipynb` → `03_process_attributes.R`) con el input nuevo, y se comparó celda por celda contra la v1.1 con `scripts/compare_outputs.py` (reproducible, ver sección "Cómo reproducir" abajo). Los resultados de esa comparación quedan en `comparison_v1.1_vs_v1.2/`.

1. Cobertura de pozos — la brecha

	Pozos v1.1	Pozos v1.2	En común
`gwl_mon.csv` / `gwl_mon_clean.csv` / `attributes.csv`	1137	1133	1133

La brecha son **4 pozos** que existen en las descargas viejas pero no en el export único nuevo (`comparison_v1.1_vs_v1.2/wells_missing_`

Código DGA	Nombre	Cuenca	Subcuenca
02942002-5	PIQUE AV-1	QS. entre Q. La Negra y Q. Pan de Azúcar	Quebrada de Taltal
02942008-4	PIQUE AV - 42	QS. entre Q. La Negra y Q. Pan de Azúcar	Quebrada de Taltal
02942011-4	ESSAN AV - 48	QS. entre Q. La Negra y Q. Pan de Azúcar	Quebrada de Taltal
02942023-8	ESSAN AV - 48	QS. entre Q. La Negra y Q. Pan de Azúcar	Quebrada de Taltal

Los 4 son puntos de monitoreo privados (prefijo ESSAN/PIQUE AV, minería) en la cuenca de Taltal, no estaciones públicas DGA — su ausencia del export del portal es esperable y no se considera un defecto de la migración.

No hay pozos en el archivo nuevo que no existieran antes (0 pozos nuevos "de más").

2. Comparación de metadatos (`attributes.csv`)

De los 1133 pozos en común, **17 valores de metadata** (en 13 pozos) difieren en más de 0.01 entre el input viejo y el nuevo (`comparison_v1.1_vs_v1.2/metadata_diffs.csv`):

cr2sub_id	Nombre	Campo	v1.1	v1.2
1700042	SALAR BELLAVISTA	lat	-21.305833	-20.734444
1700042	SALAR BELLAVISTA	lon	-69.520278	-69.618056
1700042	SALAR BELLAVISTA	elev	946	970
4400037	PARCELA 48 CUATRO ESQUINAS	lat	-29.731944	-29.918889
4400037	PARCELA 48 CUATRO ESQUINAS	lon	-71.230278	-71.269722
4308010	POZO CALVARIO	lon	-70.594722	-70.502778
8114002	POZO COIHUECO en Internado Municipal	lon	-71.871667	-71.838056
1700051/057/076/099-106 (JICA, 9 pozos)	—	elevación	—	-25 a -35 m

Son correcciones/actualizaciones reales en la base de metadatos de DGA entre la fecha en que se bajaron los reportes viejos y la fecha del export nuevo (re-levantamientos de coordenadas/cota), no errores de parsing: el formato de coordenadas del archivo nuevo (`DDDMMSS` compacto) es uniforme en los 1134 pozos y se validó contra ubicaciones conocidas antes de escribir el parser. Quedan documentadas para que quien revise sepa que no son sorpresa de la migración, pero no se "corrigieron" en ningún sentido — se usa el valor que trae cada fuente.

Las métricas agregadas (`cr2sub_mean_gwl`, `cr2sub_sd_gwl`) cambian levemente en ~110-120 pozos — esperado, porque ahora hay más meses de datos por pozo (huecos rellenados + serie extendida).

3. Series que evidencian la extensión temporal

Rango de fechas:

Archivo	v1.1	v1.2
`gwl_mon.csv`	1957-04 → 2024-12 (813 meses)	1957-04 → 2026-08 (833 meses)
`gwl_mon_clean.csv`	igual	igual

Ejemplo concreto — pozo `5423019` (el de mayor cobertura reciente), serie mensual completa (`cr2sub_v1.2_gwl_mon.csv`), generada con `scripts/plot_series_extension.py`:

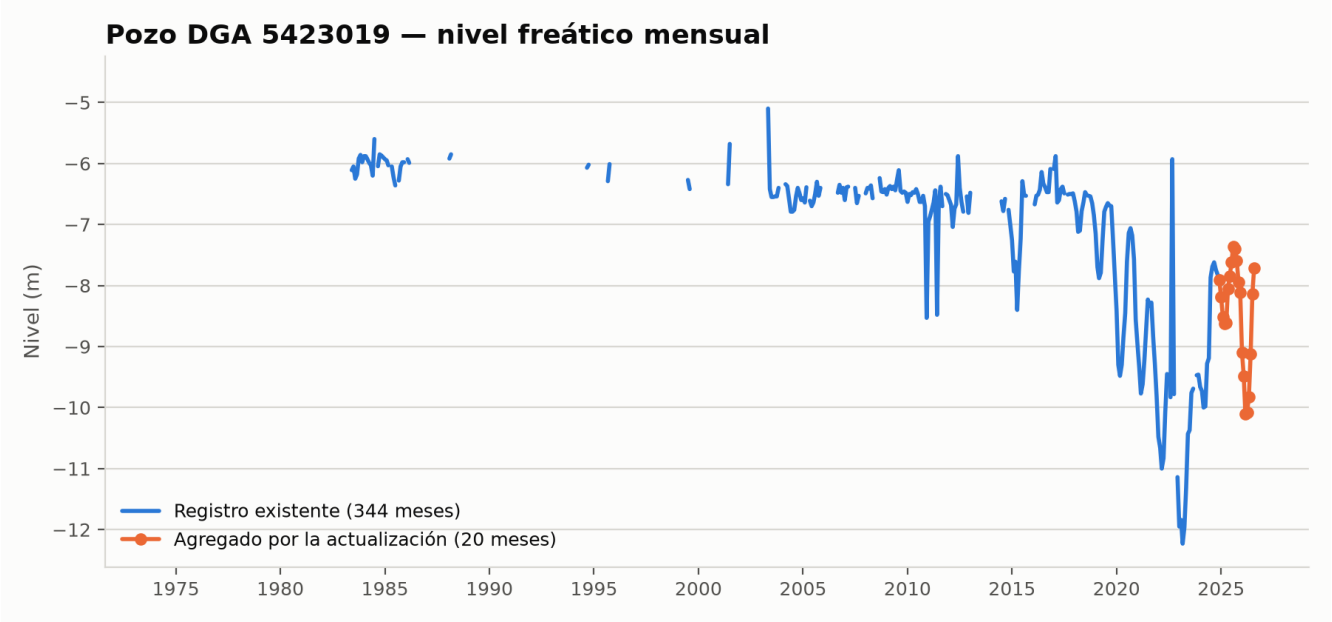


Figure 1: Serie de tiempo pozo 5423019: registro existente en azul, puntos agregados por la actualización en naranja

En azul, el registro que ya existía con el input viejo: 344 meses entre 1974-04 y 2024-12 (los cortes de la línea son huecos reales de medición, no artefactos del gráfico). En naranja, los 20 meses que agrega la actualización, de 2025-01

a 2026-08, enganchados directo a la cola del registro existente — no hay reescritura del histórico, solo extensión hacia adelante. Todos los puntos del tramo en común entre ambas fuentes (hasta 2024-12) son idénticos; el detalle completo de celdas que antes eran `NA` y ahora tienen valor está en `comparison_v1.1_vs_v1.2/gwl_mon_gap_filled.csv` (420 en `gwl_mon.csv`, 840 en `gwl_mon_clean.csv`, repartidas en huecos intermedios de otros pozos además de esta cola).

4. Cobertura mensual por región, 2020–2026

Número de pozos con dato en cada mes, por región (norte a sur), para v1.1 y v1.2 con la misma escala de color. La región de cada pozo se asigna por ubicación (cruce espacial con los límites regionales; el polígono más cercano si el punto cae fuera), no por el código DGA, cuyo prefijo es la macrocuenca BNA y no la región. El panel superior (total mensual) superpone ambas versiones: v1.2 en azul grueso y v1.1 en naranja fino. Generado con `scripts/plot_coverage_by_region.py`.

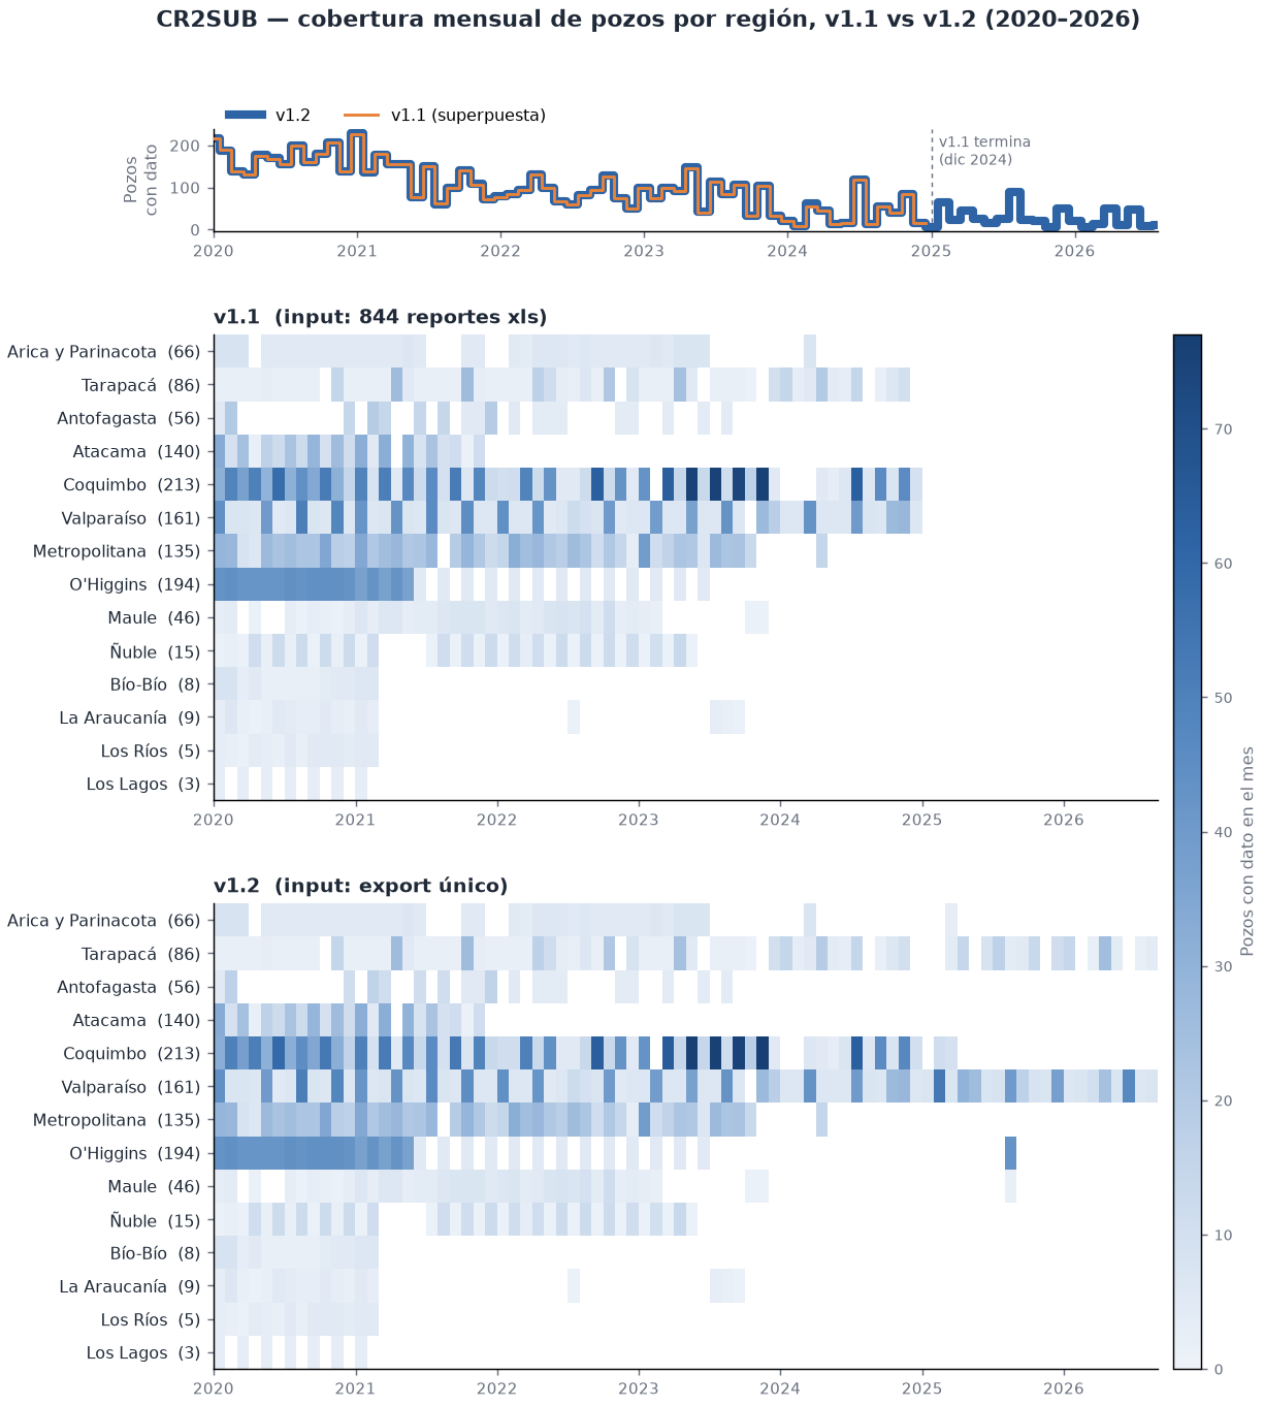


Figure 2: Cobertura mensual de pozos por región, v1.1 vs v1.2, 2020-2026

- Hasta dic-2024 las dos versiones son prácticamente idénticas; la línea naranja corre dentro de la azul.
- Desde 2025 solo v1.2 tiene datos (hasta ago-2026), concentrados en Valparaíso, Tarapacá, Coquimbo y O'Higgins. Las demás regiones no aportan meses nuevos.
- En pozos presentes en ambas versiones, v1.2 suma 600 pozos-mes en 2020–2026 (557 desde 2025 y 43 de huecos rellenados antes) y pierde 1. Por región: Valparaíso 362, Tarapacá 127, Coquimbo 63, O'Higgins 43, Arica y Parinacota 3, Maule 2.
- Los otros 21 pozos-mes que v1.2 no tiene en el periodo corresponden a los 4 pozos privados de Taltal que no están en el export nuevo (sección 1).

- La cobertura cae desde ~2020 en ambas versiones y las regiones al sur de O'Higgins casi no tienen datos desde 2021–2023.

5. Consistencia de valores (no solo cobertura)

Comparando las **921.129 celdas** (pozo × fecha) presentes en ambas fuentes en `gwl_mon.csv`:

v1.1 → v1.2	Cantidad
Valores idénticos o ambos `NA`	920.708
`NA` antes → con valor ahora (hueco rellenado)	420
Con valor antes → `NA` ahora (dato perdido)	1
Valores contradictorios (mismo pozo/fecha, valor distinto)	**0**

El único dato "perdido" es el pozo `1700028` en 2024-04 (`comparison_v1.1_vs_v1.2/gwl_mon_lost.csv`). En `gwl_mon_clean.csv` (post remoción de outliers) la cifra sube a 16 perdidos / 840 rellenados — es esperable, porque el filtro de outliers recalcula con más contexto temporal y puede marcar como outlier algo que antes, con una serie más corta, no se evaluaba igual.

Conclusión: cero conflictos de valor en ~920 mil puntos comparados. El archivo único es, en la práctica, un superset de las 3 carpetas viejas (mismos valores donde coinciden, más puntos donde antes había huecos), salvo los 4 pozos privados fuera del export del portal.

6. Atributos columna a columna (1133 pozos en común)

Generado con `scripts/compare_attributes.py` (`comparison_v1.1_vs_v1.2/attribute_column_diffs.csv`). De las 45 columnas de `attributes.csv`, solo `cr2sub_id` es idéntica; los cambios se agrupan así:

Grupo	Pozos que cambian	Causa
`dga_well_basin` / `subbasin` / `name`	1133 / 712 / 45	La DGA cambió el formato del texto (`RIO COPIAPO` → `R. Copiapo`; `EL TRANSITO` → `POZO EL TRANSITO`). No es un cambio de ubicación
Coordenadas y cota `dga_*` / `cr2sub_*`	14 a 33 según columna	Re-levantamientos en la base DGA (sección 2). Arrastran `cr2sub_elev` y `cr2sub_slp` (14 pozos)
`cr2sub_mean/sd/cv_gwl` (raw y clean)	61 a 142	Más meses de datos por pozo (secciones 3 y 5)
`cr2sub_*camels*`	273 cambian de cuenca, 77 pasan de NA a tener cuenca, 1 pasa a NA	Cambio de CAMELS-CL v1 (516 cuencas) a v2 (860). Las variables climáticas y topográficas de la cuenca se recalculan sobre el nuevo polígono
`cr2sub_*bna*`	9	Nuevo criterio de asignación: cuenca que contiene al pozo, con buffer de 500 m solo si no cae en ninguna (antes el buffer se aplicaba a todos los pozos)
`cr2sub_clsoilmap_*`	0	Sin cambios; ver sección 8

Pozos sin cuenca CAMELS: 310 en v1.1 → 230 en v1.2. El pozo `5221007` (PAPUDO Y ZAPALLAR, mismas coordenadas) tenía cuenca en v1 y ya no en v2, porque el polígono cambió.

7. Pipeline

Corrida completa con el input nuevo (`main_pipeline.py`: 01 → 01b → 02 → 03). Las salidas coinciden con las secciones 1 a 5; los CSV de `versions/v1.2/` son copia de `cr2sub/`. La asignación a cuencas ahora se regenera con `input/cr2sub_basin_lookup_tables/lookup_table_script.R` (intersección vectorial, sin dependencias externas).

8. CLSoilMaps entre pozos y entre versiones

Scripts: `scripts/validate_clsoilmaps_extraction.R` (re-extrae el suelo de todos los pozos con los rasters originales) y `compare_attributes.py`. Salidas: `clsoilmaps_*.csv` y `clsoilmaps_stored_vs_reextracted.png` en `comparison_v1.1_vs_v1.2/`.

v1.1 vs v1.2. Los valores de suelo son idénticos en 1131 de los 1133 pozos comunes. Los otros 2 son los pozos nuevos (`05120007` y `05120011`) que v1.1 tenía en NA y que ahora se extrajeron de los rasters. Pozos con suelo en NA: 66 de 1133 (fuera de la cobertura de CLSoilMaps).

Coherencia espacial. Para cada pozo y su vecino más cercano a menos de 5 km (884 pares), la correlación del valor de suelo es 0,77 a 0,95 (por ejemplo arena 0-100 cm: 0,95; arcilla 0-100 cm: 0,92), frente a ~0 para pares al azar. Los dos pozos nuevos quedan en el rango de sus vecinos (AWC 0-100 cm: 130 y 126 mm; vecinos entre 120 y 139 mm).

Verificaciones físicas. Sin valores negativos y densidad aparente entre 0,7 y 2,0 g/cm^3 en todos los pozos. Hay 9 pozos con arcilla + arena $>$ 100 % en 100-200 cm; son promedios sobre un buffer de 500 m, no mediciones, y conviene tenerlo presente.

Re-extracción vs valores guardados (1066 pozos con dato en ambos): correlación 0,997 a 0,999; mediana de la diferencia relativa 0,06 % a 0,5 %. Solo 106 a 598 pozos por variable son idénticos al milésimo, así que el buffer no se construye exactamente igual que el original, pero la diferencia es pequeña (mediana de AWC 0-100 cm: 0,1 mm sobre una mediana de 136 mm).

Hallazgo importante. Los tres pozos con mayor desvío son pozos cuyas coordenadas cambiaron entre v1.1 y v1.2 (`4308010`, `1700042` y `8114002`, sección 2). Su suelo guardado se calculó con la ubicación vieja y no se recalculó, porque el paso 01b solo extrae pozos que faltan en el CSV. El cuarto pozo que cambió de coordenadas, `4400037`, tiene valor guardado (AWC 0-100 cm: 94,7 mm) pero la re-extracción da NA. Además `6011022` y `4400017` están en NA en el valor guardado y con dato en la re-extracción (136,7 y 124,4 mm). Conviene hacer que el paso 01b recalcule también los pozos cuyas coordenadas cambian y revisar esos casos de borde de cobertura.

Cómo reproducir

Todo junto (tras `main_pipeline.py`): `review_dga_xlsx_migration/scripts/regenerate_review.sh`. Por partes:

```
cd review_dga_xlsx_migration/scripts
python3 compare_outputs.py        # series y metadatos; solo stdlib
Rscript ../../review_dga_xlsx_migration/scripts/validate_clsoilmaps_extraction.R   # desde la raíz del repo
python3 compare_attributes.py     # atributos y CLSoilMaps; pandas, matplotlib
python3 plot_series_extension.py; python3 plot_coverage_by_region.py   # figuras; geopandas
```

Lee de `../versions/{v1.1,v1.2}/*.csv` y escribe a `../comparison_v1.1_vs_v1.2/`. Para regenerar `versions/v1.2/` desde cero, correr el pipeline (`scripts/main_pipeline.py`, requiere pandas para el paso 02) y copiar los 3 CSV de `cr2sub/` ahí.